

MAKALAH

**Sistem Pembantu Deteksi Penggunaan Masker yang Baik dan Benar
Menggunakan Object Detection Faster R-CNN**



Disusun oleh Tim Yakuy 2 :

Ardacandra Subiantoro (18/427572/PA/18532)

Arief Pujo Arianto (18/430253/PA/18766)

Chrystian (18/430257/PA/18770)

**PROGRAM STUDI S1 ILMU KOMPUTER
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**

2020

Abstrak.

Daftar Isi

1	Pendahuluan	3
1.1	Latar Belakang	3
1.2	Rumusan Masalah	3
1.3	Batasan Masalah	3
2	Tujuan dan Manfaat	3
3	Metode	4
3.1	Pembelajaran Model	4
3.1.1	Faster R-CNN	4
3.2	Implementasi Model	7
4	Hasil	7
5	Kesimpulan	7
6	Lampiran	7

1 Pendahuluan

1.1 Latar Belakang

Meskipun berbagai penanganan sudah dilakukan tetapi hingga hari ini jumlah kasus COVID-19 terus meningkat. Jumlah kasus total COVID-19 di seluruh dunia sudah mencapai lebih dari 48 juta kasus, dengan lebih dari 1,2 juta kematian akibat COVID-19. Kasus COVID-19 di Indonesia sudah mencapai lebih dari 400 ribu dengan lebih dari 14 ribu kematian. Dampak negatif dari pandemi COVID-19 ini sangat terasa di Indonesia. Direktur Jenderal Pajak Kementerian Keuangan (Kemenkeu) Suryo Utomo membagi dampak pandemi COVID-19 menjadi tiga garis besar [1]. Dampak pertama adalah membuat konsumsi rumah tangga atau daya beli yang merupakan penopang 60 persen terhadap ekonomi jatuh cukup dalam. Hal ini dibuktikan dengan data dari BPS yang mencatatkan bahwa konsumsi rumah tangga turun dari 5,02 persen pada kuartal I 2019 ke 2,84 persen pada kuartal I tahun ini. Dampak kedua yaitu pandemi menimbulkan adanya ketidakpastian yang berkepanjangan sehingga investasi ikut melemah dan berimplikasi pada terhentinya usaha. Dampak ketiga adalah seluruh dunia mengalami pelemahan ekonomi sehingga menyebabkan harga komoditas turun dan ekspor Indonesia ke beberapa negara juga terhenti.

Dengan melemahnya ekonomi di Indonesia ini, banyak perusahaan juga sudah mulai untuk membuka kembali bisnis mereka seperti semula. Berbagai upaya pengawasan pun dilakukan agar setiap orang dapat beraktivitas seperti semula dengan aman tanpa adanya ketakutan tertular COVID-19. Tetapi meskipun berbagai cara pengawasan sudah dilakukan, masih banyak orang yang tidak mematuhi aturan dan tetap beraktivitas seperti biasa. Perlunya banyak pengawasan untuk mengingatkan kembali aturan yang ada di era *new normal* ini adalah salah satu cara agar semua dapat beraktivitas kembali seperti semula serta mengurangi resiko tertular COVID-19.

Tetapi untuk mewujudkan era *new normal* ini dengan baik dan efektif, dibutuhkan pengawasan serta himbauan peraturan era *new normal* ini secara skala besar dan umum sehingga dibutuhkannya banyak sekali tenaga kerja. Namun menggunakan tenaga manusia bukanlah jawaban yang tepat karena tidak efisien serta sangat sulit dan juga menyita banyak waktu apabila tenaga manusia ini mengawasi serta menghimbau setiap orang yang ada.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut permasalahan utama yang akan ditelusuri ialah :

1. Bagaimana penambahan data dapat membantu mewujudkan dan menegakkan aturan pada era *new normal* untuk dapat mengurangi penyebaran COVID-19 yang ada ?
2. Bagaimana cara model dapat mendeteksi serta membedakan pemakaian masker yang baik dan benar ?

1.3 Batasan Masalah

Batasan masalah yang akan kami gunakan adalah sebagai berikut :

- Dataset yang akan digunakan dibatasi pada Kaggle Face Mask Detection milik Larxel[2].
- Jenis gambar yang akan diklasifikasi dibatasi pada memakai masker, tidak memakai masker, dan memakai masker yang tidak benar.
- Metode penambahan data yang akan kami gunakan adalah Real-time Object Detection dengan Arsitektur Faster R-CNN[3].

2 Tujuan dan Manfaat

Tujuan utama, kami mengusulkan menggunakan model Object Detection dengan arsitektur Faster R-CNN untuk membantu mengawasi dan menghimbau penggunaan masker yang benar di tempat umum. Object Detection dengan menggunakan Faster R-CNN ini diharapkan dapat dengan baik

membedakan dan mengklasifikasi penggunaan masker dengan baik dan juga dapat secara cepat melakukan klasifikasi tersebut.

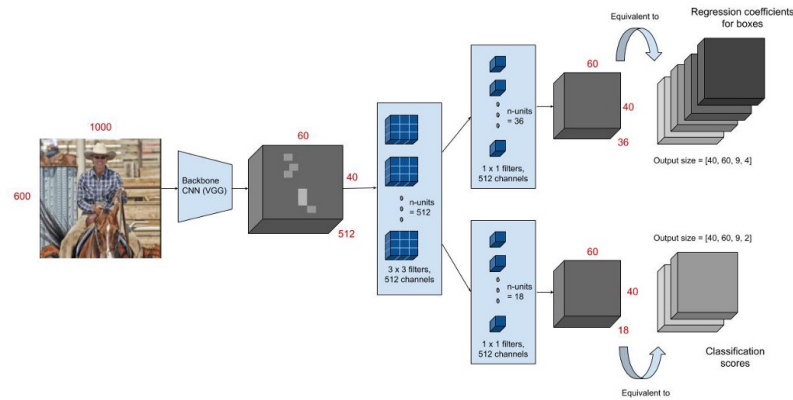
Tujuan kedua, dari hasil penambangan data tujuan utama kami, kami bertujuan untuk langsung memakai model tersebut diimplementasikan langsung dengan teknologi serta kesiapa infrastruktur yang ada. Implementasi ini diharapkan dapat membantu tenaga manusia untuk dapat secara otomatis memperingatkan selalu penggunaan masker di tempat umum supaya era *new normal* dapat terwujud. Manfaat yang kami harapkan adalah peningkatan kesadaran penggunaan masker dan kemudahan bagi tenaga manusia untuk mengawasi penggunaan masker.

3 Metode

3.1 Pembelajaran Model

3.1.1 Faster R-CNN

Faster R-CNN pertama kali dipublikasikan pada tahun 2015. Jaringan pendeteksi objek sebelum Faster R-CNN menggunakan algoritma proposal wilayah untuk membuat hipotesis lokasi objek. Jaringan seperti R-CNN dan Fast R-CNN menggunakan algoritma berbasis CPU seperti Algoritma Selective Search yang membutuhkan waktu sekitar 2 detik untuk setiap gambar. Jaringan Faster R-CNN memperbaiki masalah ini dengan menggunakan convolutional network untuk menghasilkan proposal wilayah. Perubahan ini mengurangi waktu penghitungan proposal wilayah dari 2 detik menjadi 10 milidetik dan meningkatkan representasi fitur. Faster R-CNN terdiri dari detection pipeline yang menggunakan RPN sebagai algoritma proposal wilayah dan Fast R-CNN sebagai jaringan detektor.[4]

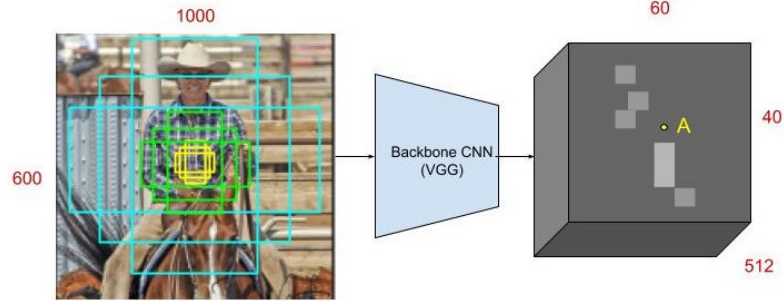


Figur 1: Arsitektur RPN

RPN (Region Proposal Network) dimulai dengan memasukkan gambar input ke dalam Backbone CNN. Gambar input diubah ukurannya sehingga sisi yang pendek 600px dan sisi yang panjang tidak lebih dari 1000px. Output dari Backbone CNN biasanya jauh lebih kecil dari ukuran gambar input, tergantung parameter stride dari Backbone CNN. Contoh Backbone CNN yang dapat digunakan adalah jaringan VGG atau ZF-Net dengan stride 16. Hal ini berarti pixel-pixel yang bersebelahan pada output jaringan sama dengan dua pixel yang terpisah sejauh 16 pixel pada gambar input.

Untuk setiap titik pada output feature map, jaringan harus belajar apakah objek terdeteksi pada gambar input pada lokasi tersebut dan mengestimasi ukurannya. Hal ini dilakukan dengan meletakkan "Anchors" pada gambar input untuk setiap lokasi pada output feature map. "Anchors"

mengindikasikan objek-objek yang mungkin terdapat pada lokasi tersebut dengan beragam ukuran dan aspect ratio.



Figur 2: Contoh "Anchors" pada Gambar Input dari Lokasi Titik A pada Feature Map

Jaringan bergerak melewati setiap pixel pada output feature map dan memeriksa apakah "anchors" yang mencakupi sebuah area pada gambar input mengandung objek atau tidak, lalu mengoptimalkan koordinat-koordinat "anchors" untuk menghasilkan kotak-kotak pembatas yang disebut proposal wilayah.

Konvolusi 3x3 dengan 512 unit diaplikasikan ke feature map untuk menghasilkan 512-d feature map untuk setiap lokasi. Lalu diikuti oleh 1x1 convolution layer dengan 18 unit untuk klasifikasi objek, dan 1x1 convolution dengan 36 unit untuk regresi kotak pembatas. 18 unit dari cabang klasifikasi akan mengeluarkan output dengan ukuran (H, W, 18) yang memberikan probabilitas apakah setiap titik dalam backbone feature map mengandung objek atau tidak di dalam semua 9 "anchors" pada titik. 36 unit dari cabang regresi akan mengeluarkan output dengan ukuran (H, W, 36) yang memberikan 4 koefisien regresi untuk setiap 9 "anchors" untuk setiap titik dalam backbone feature map. Koefisien regresi meningkatkan akurasi koordinat "anchors" yang mengandung objek.

Output feature map terdiri dari 40x60 lokasi, dengan total "anchors" sekitar 20 ribu. Ketika melatih model, semua "anchors" yang melewati batas gambar diabaikan supaya tidak berkontribusi dalam penghitungan loss. Sebuah "anchor" dianggap sampel positif bila memenuhi salah satu kondisi :

1. "Anchor" memiliki IoU (Intersection over Union) tertinggi dengan kotak groundtruth.
2. "Anchor" memiliki IoU lebih besar dari 0.7 untuk setiap kotak groundtruth.

Sebuah "anchor" dianggap sampel negatif bila IoU dengan semua kotak groundtruth kurang dari 0.3. "Anchor" yang tidak termasuk positif dan negatif akan diabaikan saja.

Setiap mini-batch untuk melatih RPN berasal dari sebuah gambar. 128 sampel positif dan 128 sampel negatif dipilih secara acak untuk menghasilkan batch. Training loss dari RPN adalah multi-task loss yang dihitung sebagai berikut :

$$L(\{p_i\}, \{t_i\}) = \frac{1}{N_{cls}} \sum_i L_{cls}(p_i, p_i^*) + \lambda \frac{1}{N_{reg}} \sum_i p_i^* L_{reg}(t_i, t_i^*).$$

i adalah index dari "anchor" dalam mini-batch. Classification loss adalah log loss dari dua kelas (objek vs bukan objek). p_i adalah nilai output dari cabang klasifikasi untuk "anchor" i , dan p_i^* adalah label groundtruth.

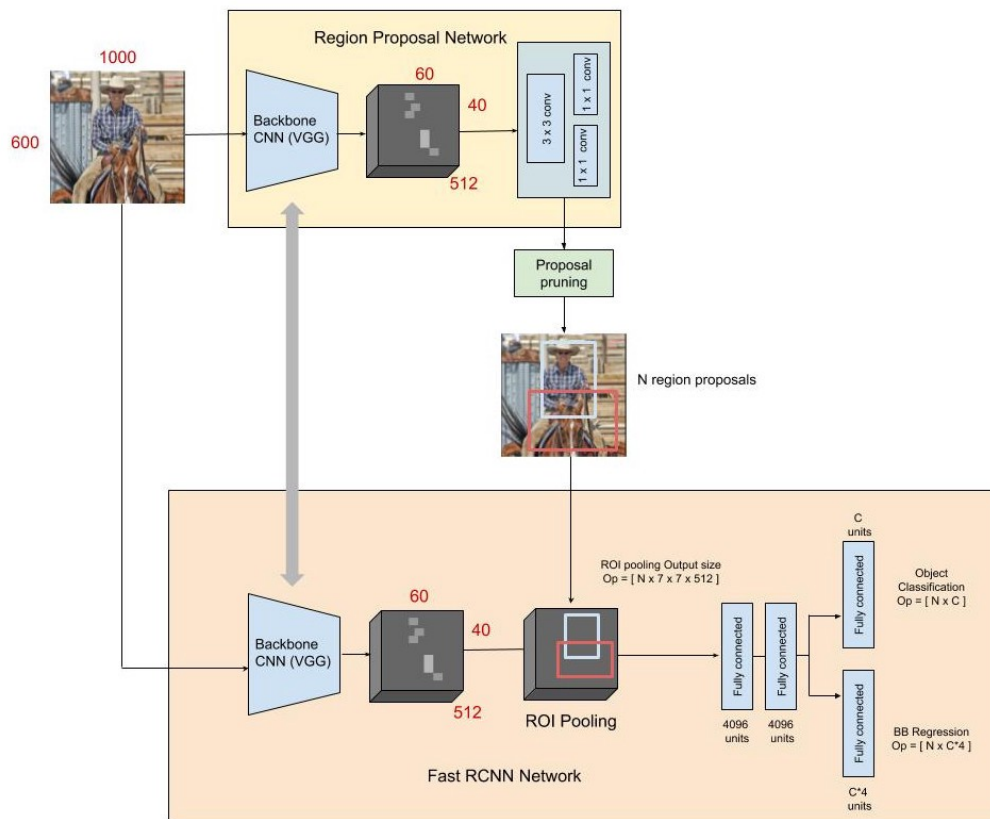
Regression loss diaktivasi hanya jika "anchor" mengandung objek. t_i adalah output prediksi dari cabang regresi dan terdiri dari 4 variabel $[t_x, t_y, t_w, t_h]$. Regression target dihitung dengan rumus berikut :

$$t_x^* = (x^* - x_a)/w_a, \quad t_y^* = (y^* - y_a)/h_a, \quad t_w^* = \log(w^*/w_a), \quad t_h^* = \log(h^*/h_a)$$

x, y, w, h adalah koordinat (x, y) dari titik tengah kotak pembatas dan tinggi(h) dan lebar(w) kotak. x^*, y^*, w^*, h^* adalah koordinat dan dimensi kotak-kotak groundtruth. Setiap "anchor" memiliki regresi yang berbeda, sehingga weight nya berbeda-beda. Ketika waktu pengujian, output regresi t_i bisa diaplikasikan ke kotak "anchor", dan parameter x, y, w, h untuk kotak pembatas prediksi bisa dihitung dari rumus :

$$t_x = (x - x_a)/w_a, \quad t_y = (y - y_a)/h_a, \quad t_w = \log(w/w_a), \quad t_h = \log(h/h_a)$$

Pada waktu pengujian, "anchors" dari setiap gambar melewati beberapa langkah post-processing untuk mengirimkan kotak-kotak pembatas objek. Koefisien regresi diaplikasikan ke "anchor" untuk lokalisasi yang tepat. Untuk kumpulan kotak-kota yang tumpang tindih, kotak yang memiliki IoU lebih dari 0.7 dengan kotak lain akan dibuang. Hanya proposal kotak pembatas sejumlah n terbaik dari RPN akan dipilih.



Figur 3: Arsitektur Faster R-CNN Lengkap (RPN + Fast R-CNN)

Arsitektur Faster R-CNN lengkap terdiri dari RPN sebagai algoritme proposal wilayah dan Fast R-CNN sebagai jaringan pendeteksi. Jaringan pendeteksi Fast R-CNN juga terdiri dari Backbone CNN, ROI pooling layer, dan fully-connected layer diikuti dengan dua cabang untuk klasifikasi dan regresi kotak pembatas. Gambar input dimasukkan ke Backbone CNN untuk mendapatkan feature map. Salah satu keuntungan menggunakan RPN sebagai penghasil proposal adalah pembagian weights antara backbone RPN dan backbone Fast R-CNN. Lalu, ROI pooling layer melakukan langkah-langkah di bawah :


1. Mengambil daerah proposal dari feature map backbone.

2. Membagi wilayah menjadi sub-wilayah dengan jumlah tertentu.
3. Melakukan max-pooling dari sub-wilayah untuk mendapatkan output dengan ukuran tertentu.

Output ROI pooling layer dimasukkan ke dua fully-connected layer, lalu fitur-fitur dimasukkan ke cabang klasifikasi dan regresi. Cabang klasifikasi dan regresi berbeda dengan cabang klasifikasi dan regresi pada RPN. Disini classification layer memiliki C unit untuk setiap kelas pada tugas deteksi. Fitur-fitur masuk melewati softmax layer untuk mendapatkan nilai klasifikasi, probabilitas proposal masuk ke dalam suatu kelas. Koefisien regresi digunakan untuk meningkatkan akurasi dari kotak pembatas. Setiap kelas memiliki regresor masing-masing dengan 4 parameter sesuai dengan $C \times 4$ unit output pada regression layer.

Untuk memaksa jaringan untuk membagi weight Backbone CNN antara RPN dan Fast R-CNN, digunakan proses latihan 4 langkah :

1. RPN dilatih secara independen seperti penjelasan di atas.
2. Jaringan pendeteksi Fast R-CNN juga dilatih secara independen.
3. Weight RPN diinisialisasi dengan weight Faster R-CNN, lalu dilatih untuk tugas proposal wilayah. Weight pada lapisan-lapisan yang sama antara RPN dan Fast R-CNN tetap sama, hanya lapisan yang ada di RPN saja yang diubah.
4. Dengan menggunakan RPN baru, jaringan pendeteksi Fast R-CNN juga dilatih lagi. Hanya lapisan-lapisan yang ada di Fast R-CNN saja yang berubah weight nya.



Figur 4: Hasil Faster R-CNN dengan Backbone VGG

3.2 Implementasi Model

4 Hasil

5 Kesimpulan

6 Lampiran

Referensi

- [1] N. Zuraya. *Tiga Dampak Besar Pandemi Covid-19 bagi Ekonomi RI*. URL: <https://republika.co.id/berita/qdgt5p383/tiga-dampak-besar-pandemi-covid19-bagi-ekonomi-ri>. (2020).
- [2] Larxel. *Face Mask Detection*. May 2020. URL: <https://www.kaggle.com/andrewmvd/face-mask-detection>.
- [3] Shaoqing Ren et al. "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks". In: *Advances in Neural Information Processing Systems*. Ed. by C. Cortes et al. Vol. 28. Curran Associates, Inc., 2015, pp. 91–99. URL: <https://proceedings.neurips.cc/paper/2015/file/14bfa6bb14875e45bba028a21ed38046-Paper.pdf>.
- [4] Shilpa Ananth. *Faster R-CNN for object detection*. Aug. 2019. URL: <https://towardsdatascience.com/faster-r-cnn-for-object-detection-a-technical-summary-474c5b857b46>.